Production et publication d'une page HTML5 culturelle sémantiquement enrichie à partir de données structurées

Corpus : Festivals culturels internationaux

Master CTM — M2 | Groupe : [Shimin ZHANG, Jimelyz-Loriel HENRY, Lu YANG]

Date de rendu : 17 avril 2026

Introduction

Ce projet a pour objectif de produire une page web culturelle dynamique et sémantiquement enrichie à partir d'un corpus de données structurées. Nous avons choisi de travailler sur un corpus de dix festivals culturels internationaux, un type d'objet culturel récurrent, documenté et représentatif de la diversité des pratiques culturelles contemporaines. La chaîne de traitement mise en œuvre couvre la collecte de données publiques, leur nettoyage avec OpenRefine, leur stockage dans une base MySQL et leur affichage dynamique via PHP avec un balisage sémantique schema.org.

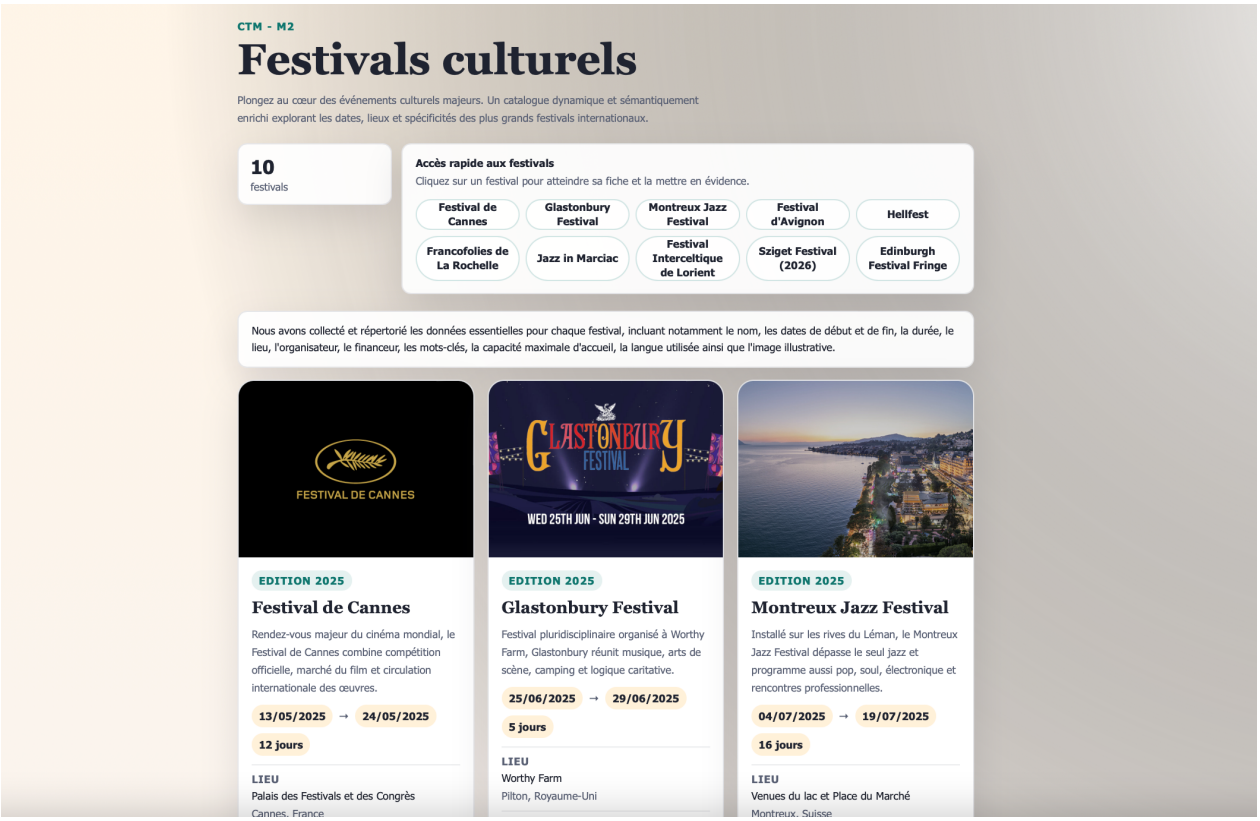

Figure 1. Page web affichant le corpus des festivals avec le balisage schema.org/Festival.

1. Choix du corpus et des sources

Le corpus réunit dix festivals culturels sélectionnés pour leur visibilité internationale, la diversité des genres culturels représentés (cinéma, théâtre, jazz, musiques actuelles, arts pluridisciplinaires) et la disponibilité d'informations publiques fiables. Les festivals retenus couvrent quatre pays : la France, la Suisse, la Hongrie et le Royaume-Uni.

Les sources retenues sont exclusivement les sites officiels des festivals. Ce choix garantit l'autorité documentaire des informations collectées. Lorsqu'une information n'était pas explicitement publiée (capacité d'accueil, financeur), la valeur a été laissée vide plutôt qu'estimée ou inventée. Une liste détaillée des sources est fournie en annexe.

2. Travail réalisé dans OpenRefine

Les données collectées ont d'abord été saisies dans un tableau Google Sheets, une ligne par festival, puis importées dans OpenRefine pour un travail de nettoyage et de normalisation.

Les opérations réalisées dans OpenRefine sont les suivantes :

- Suppression des espaces parasites en début et fin de chaque cellule (Trim whitespace) sur l'ensemble des colonnes texte.
- Vérification et harmonisation du format des dates au standard ISO 8601 (AAAA-MM-JJ) pour les colonnes start_date et end_date.
- Conversion des durées en notation ISO 8601 (P4D, P12D…) pour permettre un affichage normalisé dans la page web.
- Homogénéisation des valeurs de la colonne in_language (format : fr, fr,en…).
- Identification et mise à NULL explicite des champs non renseignés (capacité maximale, financeur) pour éviter des données approximatives.
- Génération d'un identifiant slug stable pour chaque festival (ex. : festival-de-cannes, hellfest).

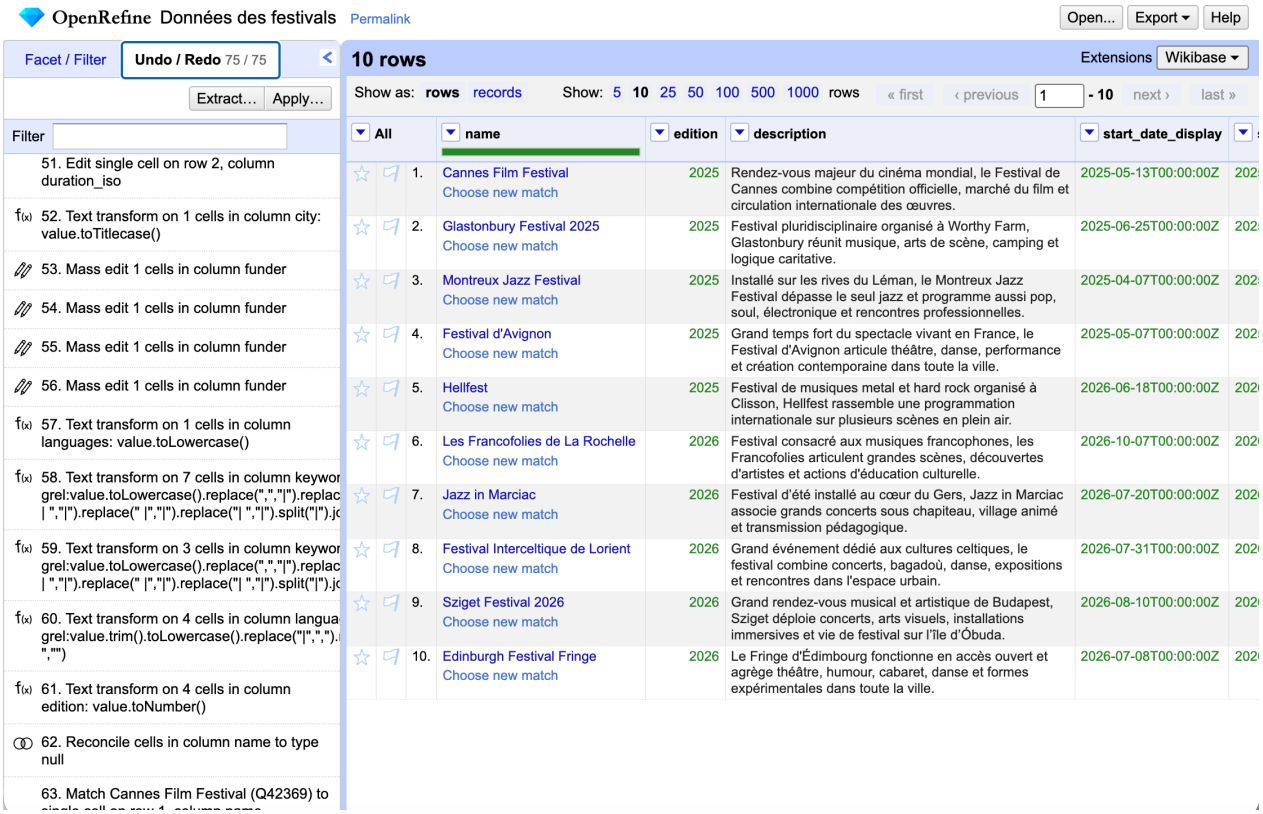

Figure 2. Vue du projet OpenRefine après les opérations de nettoyage.

3. Modèle de données

La base de données est une base MySQL nommée GLAM_FESTIVAL, encodée en UTF-8 (utf8mb4). Elle contient une seule table, Festivals, avec dix-huit champs couvrant l'ensemble des informations nécessaires à l'affichage et au balisage sémantique.

Les champs de la table sont les suivants : identifiant interne (idFestival), année d'édition, nom du festival, identifiant slug, description, dates de début et de fin, durée en ISO 8601, nom du lieu, ville, pays, nom de l'organisateur, financeur, mots-clés, capacité maximale, langues, chemin de l'image locale et URL officielle.

Ce modèle à table unique correspond à un choix de simplicité adapté à la taille du corpus. Les entités lieux et organisations ne sont pas séparées dans des tables distinctes. Cette limite est identifiée dans la section 6.

4. Choix schema.org et exposition des microdonnées

Le type sémantique retenu est schema.org/Festival, sous-type de schema.org/Event. Ce choix est plus précis qu'un simple Event car il correspond exactement à la nature des objets décrits : des événements culturels récurrents, programmés et identifiés par une édition.

Les propriétés balisées dans la page sont : name, description, startDate, endDate, duration, location (imbriqué comme schema.org/Place), organizer (imbriqué comme schema.org/Organization), funder (imbriqué comme schema.org/Organization), keywords, maximumAttendeeCapacity, inLanguage, image et url.

Les microdonnées sont implémentées directement dans le HTML via les attributs itemscope, itemtype et itemprop, conformément aux exemples fournis dans le cours. La vérification de la lisibilité par les machines a été réalisée avec le plugin OSDS.

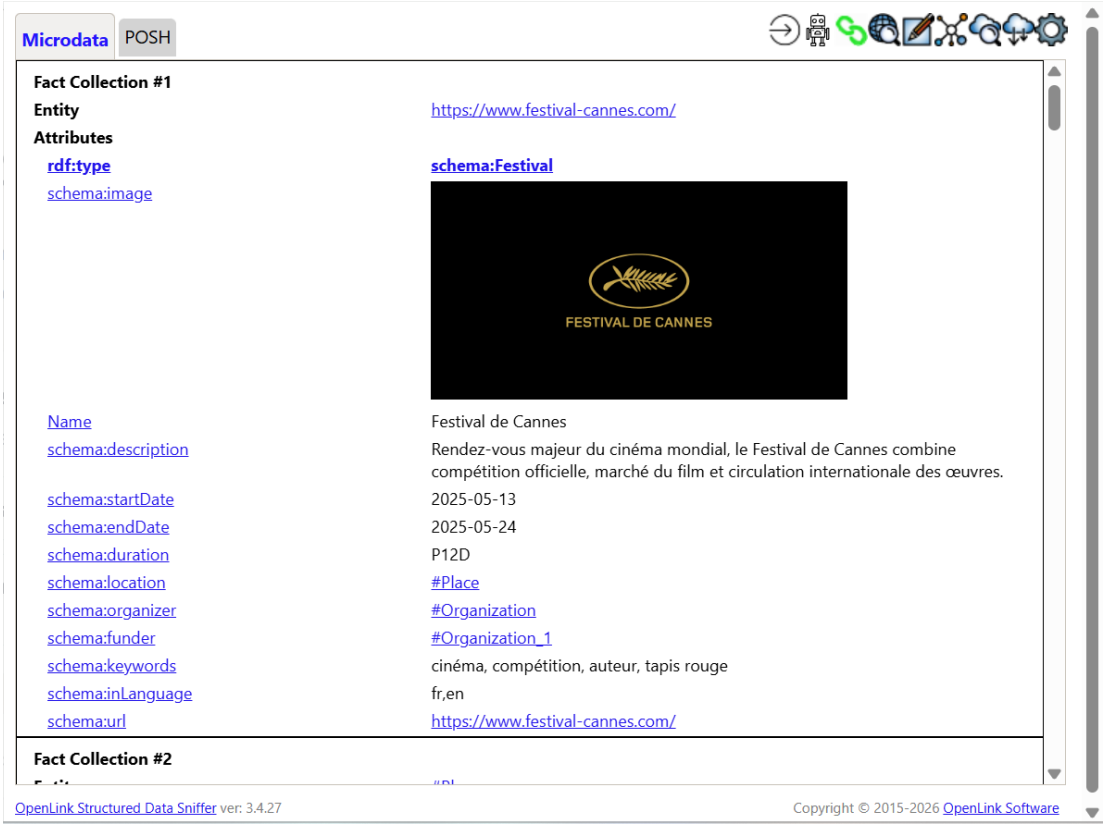

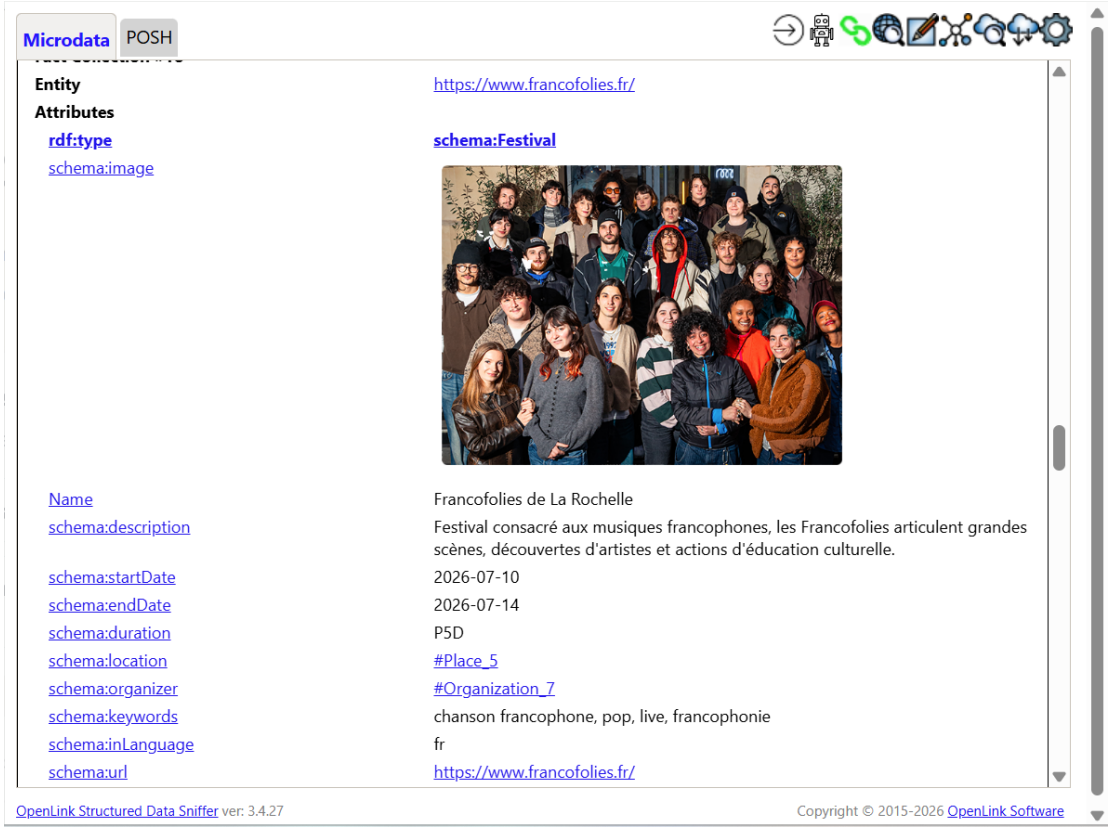

Figure 3. Validation du balisage microdonnées avec le plugin OSDS.

5. Difficultés rencontrées

Trois difficultés principales ont été rencontrées.

- Hétérogénéité documentaire : les festivals ne publient pas tous les mêmes informations. Certains détaillent leur gouvernance, leurs financeurs ou leur capacité d'accueil, d'autres non. Il a fallu accepter que certains champs restent vides.
- Encodage et caractères spéciaux : maintenir une cohérence d'encodage UTF-8 entre le fichier PHP, la base MySQL et l'export SQL a nécessité une vérification à chaque étape, notamment pour des caractères comme ceux présents dans Édimbourg ou Óbudai-sziget.
- Correspondance sémantique : les propriétés schema.org ne correspondent pas toujours directement aux formulations utilisées sur les sites officiels. La notion de capacité maximale d'accueil, par exemple, est rarement publiée de façon explicite et homogène.

6. Limites et pistes d'amélioration

Le système réalisé remplit la consigne dans sa forme actuelle, mais comporte des limites identifiées.

- Le modèle de données est dénormalisé : les lieux et organisations répétés ne sont pas dans des tables séparées.
- Certaines informations restent absentes lorsque les sources officielles ne sont pas suffisamment précises.
- La page ne propose pas de filtrage par pays, période ou genre culturel.
- Le balisage ne comprend pas encore d'alignement explicite avec des identifiants Wikidata.

Des pistes d'amélioration envisageables seraient de séparer les entités lieux et organisations dans des tables dédiées, d'ajouter des identifiants Wikidata pour aligner les données sur le graphe LOD, et de proposer un export JSON-LD en complément des microdonnées HTML.

Conclusion

Ce projet montre qu'un corpus de dix festivals culturels peut être transformé en un objet éditorial et technique cohérent : une base MySQL alimentée depuis un fichier CSV nettoyé dans OpenRefine, un affichage dynamique en PHP, des images locales stables et une couche sémantique explicite fondée sur schema.org/Festival. Le résultat est lisible pour un utilisateur humain et interprétable par des outils d'inspection de microdonnées comme OSDS.